

P3 ===== 機械学習は、、、深層学習は機械学習の一部。データをうまく活かすもの。予測や知識を得るためのコンピュータアルゴリズム 正解データを与えて、そのデータを模倣するようにモデルを学習させる。

知ってたり過去に似たデータを持っていると、その問題に対して良い性能を出すことができる。知らない問題への対応性能を“汎化”性能という。量は用意するけど、質が高くないと汎化がうまく行かない。※ 人は当たり前のように汎化している。

P5 ===== 予測対象が連続値か、離散値かで使える手法が異なる。やりたいことが決まって、データのありなしに応じて、使える手法がきまる。

P6 ===== 線を構築することを学習という。

P8 回帰 ===== 売上予測、需要予測

P9 分類 ===== 故障検知、

P10 クラスタリング ===== 優良顧客のセグメンテーション、似た問い合わせを抽出 教師データがなくてもつかえる。しかし、出来たグループの解釈は人間がやらないといけない。もし、そのグループを人間が解釈できたらかなりの儲けもの。

P11 次元圧縮 ===== データの圧縮、音源分離、白黒の画像は各ピクセルに0, 1が入ってる。情報量がとても多い。これを他の空間にマッピング（次元を圧縮）してデータをシンプルにする。簡単に扱いたいときに使える。

P14 ===== 運用していく中で、新たに正解ラベルを取れるかどうか？という点が非常に大事。追加の学習ができるから というのが理由。

たとえば、機械の故障検知とかを例に考える。オイルがきれいに塗られているような新品の機械から取得できるデータと、劣化が進んだ機械から取得できるデータは実は質が異なる。納入直後は性能が良くても、劣化が進むと故障検知機能も衰えることになる。これを避けるために追加学習が有効。

運用開始してからも、再学習が必要なんだということを理解しておく。入力データの質がどんどん変わっていくので、その分の補正が必要。

P15 ===== 予測したい現象が学習データに含まれてないときつい。あくまで模倣するところに重きがあるので。

P17 ===== 今日扱うアルゴリズム。これらを一つずつ紹介していく。

データ間の距離を測って分類していく方法。ってなに？k近傍法（講義では触れない）

P18 ロジスティック回帰 ===== 2値分類問題に対して使う。広告を、踏むか/踏まないか？病気が、あるか/ないか？など。

p19 =====

オッズ比を考える。これは、要は確率の比。表を出す確率を p とする。表と裏の2宅しか無いから裏が出る確率は $1-p$ 。たとえば、 $p=0.75$ なら、裏は 0.25 なので、オッズ比は 3 となる。これは、表：裏 = $3 : 1$ という意味になる。

ところで、 p は確率なので(0~1)しか取らない。オッズ比は(0~inf)まで取る。logをオッズ比につけたロジット関数は(-inf ~ inf)まで取る。このロジット関数の値域は直線の値域と一致する。(というか、合わせに行った。)

p20 =====

結局の所、ロジスティック回帰の気持ち的には、直線を引いてデータの空間を2つに分けたい。ただし、実際には出力は確率である点に注意。

特徴量 x とパラメーター w で表される直線をロジット関数に対応付ける。ロジット関数を扱うことで、確率の値域と直線の値域を一致させることができると、前スライドで説明した。なお、ラベルはtrue/falseしか無いので、0か1しか無い。

p について書き直すと、シグモイド関数の形になる。この関数の値域は0から1で、確率のような値が出てくる。

- ・気をつけること。特徴量として、入力に変なものを入れてしまうと、その変数につくパラメーターの調整が必要になる。学習時に、このパラメーターがうまく定まらなくて、ノイズになる。だから特徴量は注意深く選びましょう。というはなし。

- ・その他：境界の等高線は直線になる。ラベルの境界である確率0.5の等高線は直線になるのは式の形から当たり前のことだとわかる。上から2番めの式に境界である確率1/2つまり $p=0.5$ を入れたとき、右辺は直線の式になってる。

P 21 ===== このページは、あくまで「お気持ち」。 y は正解ラベル。 z は先程の特徴量とパラメーターをかけたもの。

実際の損失関数は、交差エントロピー。（とあるラベルが出る確率が高くなるように調整する関数）

入力 z (x 、 w) と y の相関が強くないと、 w が定まらなくて学習がうまく行かない。

P22 =====

2値分類を何回も繰り返していく。と、多クラス分類ができる。

p23 ===== バリアンス、バイアス という概念がある。両方を小さくしていくと、良い機械学習モデルができるが、実際はトレードオフ。

バイアスはとても小さいけど、バリアンスが大きいときは、過学習という現象が起きている。過学習：全部の点を通るように線を引いてしまっている。

過学習しているかどうかを評価しながら学習を止める。（あとでやる）

p 2 4 ===== 正則化項を入れて特徴量選択させましょう。不要な特徴量に付くパラメーターを0に落としてくれる効果がある。

(最初にとりあえず全部の特徴量を入れて相関の強さを見ても良い。)

演習では、 C というパラメーターがこれに相当する。注意点。これを使うには標準化が必要。必要なモデルとそうでないモデルがあるので注意。ロジスティック回帰は標準化すると性能上がる。このへんは使うモデルごとに調べましょう。

- ・L1正則化(ラッソ)：パラメーター w のノルム。多くの特徴量の重みを完全に0にして不要なパラメーターを削る手法。

- ・L2正則化(リッジ)：パラメーター w の2乗。大きな特徴量にペナルティーを科して過学習を防ぐ手法。

p26 ===== if文の条件式、ツリー構造を自動的に作ってくれる。昔は有識者から聞いてた。

P36 ===== 機械学習はデータとモデルのパラメーターでほぼ性能が決まる。データ大事。

一番大変なのは問題設定。(どんな値を予測するかを決める。) その後の前処理にも結構時間をとられることが多い。

前処理の際に気をつけることを紹介していく。入手したデータセットに困った(変な)データがよく入ってる。時折変なデータ入ってる。単位が違うとか、計器の機種が違う、熱暴走によって異常値データが入ってる、ケーブルノイズ、etc

データの品質チェックがされてないと変なデータが紛れ込んで。とりあえずデータをとっておこうみたいなノリで集めると起こりがち。

こういったデータが入っていると、バイアス、バリエーションが大きくなって学習がうまく行かない。まだ、データが大量にあったら良いんでしょ?的な人がいるが全然違うことを理解しておくべき。

機械学習したかったら、取得データの品質設計からやるのがベスト。どんなすごいデータサイエンティストも、悪い品質のデータセットを渡されてしまうとどうしようもない。

p 37 ===== 決定木は0があってもどうにかなったが、、、基本的にはけすのが良い。

欠損に引きずられてしまうので。

データの量が多かったら欠損値があるデータを省けばいいが、データ量が希少な場合は代表値で埋めたり別の方法を検討する。しかし、全体の代表値で置き換えると結構バイアスが入る。グループごとの代表値で置き換えるのが良い。

回帰や分類で欠損を埋めることもできるが、、、機械学習するために機械学習することになりゴールが遠のくので、避けたい。

P38 =====

データの種類には尺度がある。どういうふうに変換するかは色んな方法がある。

p 40 ===== 順序尺度：大小に意味があって、数値の間隔に意味はない。

p 42 ===== 機械学習をする時、既存の特徴量をかけたり足したりして新たな特徴量を作る。このときに、尺度を意識しないとただの数値羅列になってしまう。言葉だとすぐにわかるが、数値になると紛らわしい。特徴量を作る時は注意しましょう。

p 43 ===== データのレンジがバラバラ。このまま使えるアルゴリズムもあるが、大きな数値に引っ張られてしまう。

p 46 ===== 通常、学習用とテスト用の2つに分けるだけだが、データが大量にある場合は、学習用、テスト用、検証用、の3つに分けることがある。

学習用：モデルパラメーターを決める用。テスト用：最終モデルの汎化性能の評価用。検証用：ハイパーパラメーターの評価・選択用。グリッドサーチなどで総当たりしてハイパラを決める。演習で出てきたパラメーターのCとかはハイパーパラメーター。

学習用と検証用を区別するのは、学習用のみに最適化したパラメーターを選ばないようにするため。つまり、未知データに強い設定を選ぶため。

p 48 ===== 状態、つまり変化を扱える。

環境とか報酬の設定を用意できれば有用。

p 55 =====

$Q(s,a)$:更新前のQ値 $r(s,a)$:得られた報酬 $Q(s',a')$:遷移した先の状態の価値。

Q学習は、実際に観測した経験だけを使っているのでモデルフリーの手法